

这是标题

陈烁龙

2022 年 9 月 14 日

目录

| | | |
|-----|---------------------|---|
| 1 | 概述 | 1 |
| 2 | 数学推导 | 1 |
| 2.1 | 系统状态向量和状态误差向量 . . . | 1 |
| 2.2 | 系统的过程模型 | 1 |
| 2.3 | 测量模型 | 2 |
| 2.4 | 滤波更新的技巧 | 3 |

插图

表格

1 概述

论文名字：《Robust Stereo Visual Inertial Odometry for Fast Autonomous Flight》，提出了一种基于滤波器的双目视觉加惯导的里程计算法。由于其主要应用于小型的飞行机器上，所以算法的实时性和精度是比较需要考量的地方。小型飞行器的挂载能力通常有限，不能使用比较大的传感器，所以视觉相机和 IMU 就成为了 SLAM 的首选传感器。

另外，滤波的方式虽然略逊色于基于优化的方式，但是其计算量小，是比较合适的。至于选择使用双目相机，是因为其相比与单目相机，适应场景更强，当然也会带来额外的计算量。

该论文使用了紧耦合的方式组织惯导系统和视觉系统。

2 数学推导

2.1 系统状态向量和状态误差向量

首先，定义状态向量：

$$\mathbf{x}_I = \left({}^I_G \mathbf{q}^T \quad \mathbf{b}_g^T \quad {}^G \mathbf{v}_I^T \quad \mathbf{b}_a^T \quad {}^G \mathbf{p}_I^T \quad {}^I_C \mathbf{q}^T \quad {}^I \mathbf{p}_C^T \right)^T$$

其中： ${}^I_G \mathbf{q}^T$ 表示从 G 系（全局坐标系，论文里是惯性坐标系）到 I 系（IMU 的坐标系，由于载体坐标系和 IMU 的坐标系重合，所以就是载体坐标系）的姿态变换四元素； \mathbf{b}_g^T 表示陀螺的零偏； ${}^G \mathbf{v}_I^T$ 表示载体坐标系想对于惯性坐标系的速度向量； \mathbf{b}_a^T 表示加速度计的零偏； ${}^G \mathbf{p}_I^T$ 表示载体坐标系想对于惯性坐标系的位置向量； ${}^I_C \mathbf{q}^T$ 表示相机坐标系想对于载体坐标系的姿态四元素； ${}^I \mathbf{p}_C^T$ 表示相机坐标系想对于载体坐标系的位置向量。

而后，定义状态的误差向量：

$$\tilde{\mathbf{x}}_I = \left({}^I_G \tilde{\boldsymbol{\theta}}^T \quad \tilde{\mathbf{b}}_g^T \quad {}^G \tilde{\mathbf{v}}_I^T \quad \tilde{\mathbf{b}}_a^T \quad {}^G \tilde{\mathbf{p}}_I^T \quad {}^I_C \tilde{\boldsymbol{\theta}}^T \quad {}^I \tilde{\mathbf{p}}_C^T \right)^T$$

注意，这里使用轴角来替换四元素表示姿态，由一个四维向量变成了三维向量。这里的误差是这么定义的：

1. 姿态：

$$\tilde{\mathbf{q}} = \delta \mathbf{q} = \mathbf{q} \otimes \hat{\mathbf{q}}^{-1}$$

$$\tilde{\mathbf{q}} = \delta \mathbf{q} \approx \begin{pmatrix} \frac{1}{2} {}^G \tilde{\boldsymbol{\theta}}^T & 1 \end{pmatrix}^T$$

这是因为对于轴角 $\boldsymbol{\theta}$ 而言，其构成的四元素为：

$$\mathbf{q} = \begin{pmatrix} \frac{\sin \|\frac{1}{2} \boldsymbol{\theta}\|}{\|\frac{1}{2} \boldsymbol{\theta}\|} \frac{1}{2} \boldsymbol{\theta} \\ \cos \|\frac{1}{2} \boldsymbol{\theta}\| \end{pmatrix}$$

当向量 $\boldsymbol{\theta}$ 是小角度时，可以得到上文中的近似（类似于取极限）。

2. 其他状态向量

对于其他状态向量，其误差向量可以表示为（以 ${}^G \mathbf{p}_I^T$ 为例）：

$${}^G \tilde{\mathbf{p}}_I^T = {}^G \mathbf{p}_I^T - {}^G \hat{\mathbf{p}}_I^T$$

上文描述的就是 IMU 的状态向量，而相机的状态误差向量则为：

$$\tilde{\mathbf{x}}_{C_i} = \left({}^G \tilde{\boldsymbol{\theta}}^T \quad {}^G \tilde{\mathbf{p}}_{C_i}^T \right)^T$$

注意，相机的位姿在同一个状态解算中有多个。综上，整个系统的状态误差向量为：

$$\tilde{\mathbf{x}} = \left(\tilde{\mathbf{x}}_I^T \quad \tilde{\mathbf{x}}_{C_1}^T \quad \tilde{\mathbf{x}}_{C_2}^T \quad \dots \quad \tilde{\mathbf{x}}_{C_N}^T \right)^T$$

2.2 系统的过程模型

该部分主要的目的是得到在 EKF 中预测部分的状态转移方程和误差模型，因此，在预测步骤中，我们主要基于的是 IMU 的状态。首先是 IMU 状态的微分方程，其描述了 IMU 状态随时间变化的规律：

$$\begin{cases} {}^I_G \dot{\mathbf{q}} = \frac{1}{2} \Omega(\hat{\boldsymbol{\omega}}) {}^I_G \hat{\mathbf{q}} \\ \dot{\mathbf{b}}_g = \mathbf{0}_{3 \times 1} \\ {}^G \dot{\mathbf{v}} = C({}^I_G \hat{\mathbf{q}})^T \hat{\mathbf{a}} + {}^G \mathbf{g} \\ \dot{\mathbf{b}}_a = \mathbf{0}_{3 \times 1} \\ {}^G \dot{\mathbf{p}}_I = {}^G \hat{\mathbf{v}} \\ {}^I_C \dot{\mathbf{q}} = \mathbf{0}_{3 \times 1} \\ {}^I \dot{\mathbf{p}}_C = \mathbf{0}_{3 \times 1} \end{cases}$$

其中：\$C(\star)\$ 表示将四元素表示的姿态变换成旋转矩阵。另外：

$$\begin{cases} \hat{\omega} = \omega_m - \hat{b}_g \\ \hat{a} = a_m - \hat{b}_a \\ \Omega(\hat{\omega}) = \begin{pmatrix} -[\hat{\omega}]_{\times} & \hat{\omega} \\ -\hat{\omega}^T & 0 \end{pmatrix} \end{cases}$$

上两个式子表示将 IMU 器件的偏差从原始测量值中移除。于是，我们可以得到如下的微分方程：

$$\begin{cases} \dot{\tilde{x}}_I = F\tilde{x}_I + G\mathbf{n}_I \\ \mathbf{n}_I = \begin{pmatrix} \mathbf{n}_g^T & \mathbf{n}_{\omega g}^T & \mathbf{n}_a^T & \mathbf{n}_{\omega a}^T \end{pmatrix}^T \end{cases}$$

其中：\$\mathbf{n}_g\$ 表示陀螺的高斯噪声，\$\mathbf{n}_a\$ 表示加速度计的高斯噪声，\$\mathbf{n}_{\omega g}\$ 表示陀螺的随机游走速率，\$\mathbf{n}_{\omega a}\$ 表示加速度计的随机游走速率。具体系数矩阵 \$\mathbf{F}\$ 的和 \$\mathbf{G}\$ 形式请查看论文附录 A。比如，\$\mathbf{F}\$ 的第三行第一列的矩阵块为：\$-C(\hat{q})^T [\hat{a}]_{\times}\$，推导：

$$\begin{aligned} {}^G\dot{\mathbf{v}} - {}^G\dot{\tilde{\mathbf{v}}} &= C(\hat{q})^T (\mathbf{a}_m - (\mathbf{b}_a - \tilde{\mathbf{b}}_a)) + {}^G\mathbf{g} \\ \rightarrow {}^G\dot{\tilde{\mathbf{v}}} &= -C(\hat{q})^T (\mathbf{a}_m + \tilde{\mathbf{b}}_a - \mathbf{b}_a) - {}^G\mathbf{g} \\ \rightarrow \frac{\partial {}^G\dot{\tilde{\mathbf{v}}}}{\partial {}^I\tilde{\boldsymbol{\theta}}} &= -\mathbf{I} \cdot C(\hat{q})^T [\mathbf{a}_m + \tilde{\mathbf{b}}_a - \mathbf{b}_a]_{\times} \\ &= -C(\hat{q})^T [\hat{\mathbf{a}}]_{\times} \\ \rightarrow \frac{\partial {}^G\dot{\tilde{\mathbf{v}}}}{\partial \tilde{\mathbf{b}}_a} &= -C(\hat{q})^T \end{aligned}$$

这样，也得到了 \$\mathbf{F}\$ 的第三行第四列的矩阵块（求导的地方使用了李代数左乘扰动模型，即如何处理包含姿态的矩阵对姿态的求导）。

得到连续的状态微分方程之后，我们需要对其进行离散化，才能在实际工程上应用。也就是我们要求解上面的微分方程。利用四阶 Runge-Kutta 方法，可以得到¹：

$$\begin{cases} \Phi_k = \Phi(t_{k+1}, t_k) = e^{\int_{t_k}^{t_{k+1}} F(\tau) d\tau} \\ \mathbf{Q}_k = \int_{t_k}^{t_{k+1}} \Phi(t_{k+1}, \tau) \mathbf{G} \mathbf{Q} \mathbf{G}^T \Phi(t_{k+1}, \tau)^T d\tau \end{cases}$$

¹推导过程可以参考吴云老师的《最优估计》教材第三章。

其中 \$\Phi(t_{k+1}, t_k)\$ 即为从时刻 \$t_k\$ 到时刻 \$t_{k+1}\$ 的状态转移矩阵。而 \$\mathbf{Q}_k\$ 即为系统的噪声协方差矩阵。根据卡尔曼滤波器的状态预测步骤，我们对上一时刻的状态进行预测，得到当前时刻的状态和其协方差矩阵：

$$\begin{cases} \tilde{\mathbf{x}}_{I_{k+1}|k} = \Phi(t_{k+1}, t_k) \tilde{\mathbf{x}}_{I_k} \\ \mathbf{P}_{II_{k+1}|k} = \Phi(t_{k+1}, t_k) \mathbf{P}_{II_k|k} \Phi(t_{k+1}, t_k)^T + \mathbf{Q}_k \end{cases}$$

最后，在预测部分，我们的协方差矩阵为（注意，相机状态与 IMU 状态之间的协方差矩阵块在预测时，需要作用一个系数矩阵）：

$$\mathbf{P}_{k+1|k} = \begin{pmatrix} \mathbf{P}_{II_{k+1}|k} & \Phi_k \mathbf{P}_{IC_{k+1}|k} \\ \mathbf{P}_{IC_{k+1}|k}^T \Phi_k^T & \mathbf{P}_{CC_{k+1}|k} \end{pmatrix}$$

当新的相机位姿到来时，我们需要纳入进来。状态向量部分的增加如前面所述，而协方差矩阵则为：

$$\mathbf{P}_{k|k} = \begin{pmatrix} \mathbf{I}_{21+6N} \\ \mathbf{J} \end{pmatrix} \mathbf{P}_{k|k} \begin{pmatrix} \mathbf{I}_{21+6N} \\ \mathbf{J} \end{pmatrix}^T$$

其中，\$\mathbf{J}\$ 矩阵可以通过误差传播得到（关心的是新相机位姿和 IMU 位姿之间的关系）：

$$\begin{cases} {}^C\hat{\mathbf{q}} = {}^C\hat{\mathbf{q}} \otimes {}^I\hat{\mathbf{q}} \\ {}^G\hat{\mathbf{p}}_C = {}^G\hat{\mathbf{p}}_I + C(\hat{q})^T {}^I\hat{\mathbf{p}}_C \\ \frac{\partial {}^C\hat{\mathbf{q}}}{\partial \delta {}^I\boldsymbol{\theta}} = C^T(\hat{q}) \\ \frac{\partial {}^G\hat{\mathbf{p}}_C}{\partial \delta {}^I\boldsymbol{\theta}} = C(\hat{q})^T [{}^I\hat{\mathbf{p}}_C]_{\times} = C^T(\hat{q}) [{}^I\hat{\mathbf{p}}_C]_{\times} \\ \frac{\partial {}^G\hat{\mathbf{p}}_C}{\partial {}^G\hat{\mathbf{p}}_I} = \mathbf{I}_{3 \times 3} \end{cases}$$

2.3 测量模型

测量模型参考李圣雨师兄的论文对应的目录文件 (lishengyu)。注意里面用到了一个技巧，在构建测量模型是，通过在方程上左乘特征点的左零空间，将特征点边缘化，以加速求解。

2.4 滤波更新的技巧

在 EKF 中，每次得到新 IMU 数据，都会进行状态预测，但是测量更新并不是一直在做。有两种条件触发测量更新：

1. 当跟踪的特征丢失的时候，进行测量更新。
这时该特征点对应的相机帧不再增加（因为已经跟踪丢失了，不像 ORB-SLAM 一样进行重定位操作），即使的进行测量更新可以修正窗口内的系统状态。
2. 当窗口的大小到达限制上限。设定一个窗口大小，当实际的窗口大小到达限制大小时，意味着要丢弃部分相机帧，所以即使进行测量更新。

至于如何丢弃相机帧，论文的做法是每隔一个更新步骤就移除两个相机帧。具体而言，基于窗口内倒数第二帧和倒数第二帧之间的运动，要么最老的一个相机帧被移除，要么倒数第二帧被移除。重复这样做两次，就可以移除掉两个帧。由于倒数第一帧（最新的一帧）保持着提取的特征点，所以不考虑移除。

这么做是有现实背景的，当载体高速运动是，倒数第二帧和倒数第二帧之间的运动会很大，那么移除掉最老的一个相机帧；如果倒数第二帧和倒数第二帧之间的运动很小（比如飞行器载体悬停），那么移除掉倒数第二帧。